

Comparando métodos de classificação no *dataset Heart Disease Dataset*

Hermes Soares de Jesus¹, Paulo Roberto Bomfim Rosa¹

¹Centro de Ciências Exatas e Tecnológicas – Universidade Estadual do Oeste do Paraná
Campus Cascavel (Unioeste)
Caixa Postal 711 – 85.819-110 – Cascavel – PR – Brazil

hermes.jesus@unioeste.br, paulo.rosal4@unioeste.br

Abstract. *This work compares different classification methods applied to the Heart Disease Dataset. Monolithic classifiers, joint methods and classifier combination strategies were evaluated. The database was divided into training, validation and test sets, and the experiment was repeated 20 times to increase the reliability of the analysis. Final performance was evaluated by accuracy on the test set. The researchers indicated that the Decision Tree was the best monolithic classifier result, with an average accuracy of 95.49%, while the Random Forest presented the best overall performance, with 96.27%. Statistical tests showed that Random Forest significantly outperformed the best monolithic model.*

Resumo. *Este trabalho compara diferentes métodos de classificação aplicados ao Heart Disease Dataset. Foram avaliados classificadores monolíticos, métodos ensemble e estratégias de combinação de classificadores. A base foi dividida em conjuntos de treinamento, validação e teste, e o experimento foi repetido 20 vezes para aumentar a confiabilidade da análise. O desempenho final foi medido pela acurácia no conjunto de teste. Os resultados indicaram que a Árvore de Decisão foi o melhor classificador monolítico, com acurácia média de 95,49%, enquanto o Random Forest apresentou o melhor desempenho geral, com 96,27%. Os testes estatísticos mostraram que o Random Forest superou significativamente o melhor modelo monolítico.*

1. Introdução

Neste trabalho, foi realizada uma comparação entre diferentes métodos de classificação utilizando o *Heart Disease Dataset* [Lapp 2019]. O objetivo principal foi avaliar o desempenho de classificadores monolíticos, métodos ensemble e estratégias de combinação de classificadores, verificando quais abordagens apresentaram melhores resultados para a base analisada.

Foram avaliados os classificadores K-Nearest Neighbors (KNN), Árvore de Decisão, Naive Bayes, Support Vector Machine (SVM) e Multilayer Perceptron (MLP). Além desses modelos individuais, também foram utilizados métodos baseados em Sistemas de Múltiplos Classificadores, como Bagging, Random Forest e Boosting. Por fim, foram aplicadas estratégias de combinação das saídas dos classificadores monolíticos, incluindo Regra da Soma, Voto Majoritário e Borda Count.

Para tornar a comparação mais robusta, o experimento foi repetido 20 vezes. Em cada execução, a base foi dividida em conjuntos de treinamento, validação e teste, sendo

o conjunto de validação utilizado para a escolha dos melhores hiperparâmetros de cada modelo. A avaliação final foi realizada com base na acurácia obtida no conjunto de teste, considerando também a média e o desvio padrão das execuções. Além disso, foram aplicados testes estatísticos não paramétricos com 95% de confiança, a fim de verificar se as diferenças observadas entre os métodos eram estatisticamente significativas.

2. Sobre o *Dataset*

Este trabalho foi realizado utilizando a base de dados *Heart Disease Dataset* [Lapp 2019], a qual é formada por 1.025 registros de pacientes classificados entre os que possuem e os que não possuem problemas cardíacos, sendo esta a classe-alvo do estudo. Este *dataset* origina-se a partir de quatro conjuntos de dados: Cleveland, Hungria, Suíça e Long Beach V. Ele é composto por 13 atributos, além do rótulo de classificação. São apresentados na Tabela 1 os atributos que compõem o conjunto de dados mais o rótulo, juntamente com o significado e o tipo de dado de cada um.

O *dataset* conta com 526 amostras com a presença de doença do coração e 499 sem a doença. Não foi necessário realizar nenhum tratamento prévio nos dados, visto que eles já se apresentam em formatos discreto e contínuo, uma configuração ideal para o desenvolvimento de modelos de aprendizado de máquina. Além disso, o conjunto de dados é completo, dispensando a necessidade de tratamento de valores ausentes.

3. Metodologia

A metodologia experimental adotada neste trabalho teve como objetivo avaliar e comparar o desempenho de diferentes métodos de classificação aplicando-os a uma mesma base de dados. Todo o experimento foi repetido 20 vezes, de forma que em cada repetição, os dados fossem reorganizados aleatoriamente antes da divisão dos conjuntos.

A princípio, a base de dados foi dividida em três subconjuntos sendo: treinamento, validação e teste. O conjunto de treinamento correspondeu a 50% da base original, enquanto os conjuntos de validação e teste corresponderam a 25% cada. Esta divisão, teve como objetivo manter em todos os subconjuntos, a mesma proporção das classes presentes na base original. Desta forma, buscou-se evitar que alguma classe fosse representada de maneira desbalanceada durante o treinamento ou a avaliação dos modelos.

Após a separação dos dados, foram treinados os modelos de classificação K-Nearest Neighbors (KNN), Árvore de Decisão, Naive Bayes, Support Vector Machine (SVM) e Multilayer Perceptron (MLP). Além desses classificadores individuais, também foram avaliadas estratégias baseadas em Sistemas de Múltiplos Classificadores, incluindo Random Forest, Bagging e Boosting. Por fim, foram implementadas estratégias de combinação dos classificadores monolíticos, utilizando as saídas dos modelos previamente treinados.

Em cada uma das 20 execuções, os modelos foram treinados com o conjunto de treinamento e avaliado no conjunto de validação utilizando as diferentes combinações de alguns hiperparâmetros quando possível. A configuração que apresentou o melhor desempenho na validação foi então utilizada para classificar as amostras do conjunto de teste. Em cada uma das execuções, foi registrada a acurácia obtida por cada classificador no conjunto de teste. Ao final das repetições, foram calculadas a média e o desvio padrão

Tabela 1. Descrição dos atributos do conjunto de dados

Nº	Atributo	Descrição	Tipo de dado
1	age	Indica a idade da pessoa em anos.	Inteiro
2	gender	Indica o sexo da pessoa, em que: 0 = feminino e 1 = masculino.	Inteiro
3	cp	Indica o tipo de dor no peito, em que: 0 = angina típica, 1 = angina atípica, 2 = dor não anginosa e 3 = assintomático.	Inteiro
4	trestbps	Indica a pressão arterial em repouso da pessoa, medida em mmHg.	Inteiro
5	chol	Indica a medida de colesterol da pessoa em mg/dl.	Inteiro
6	fbs	Indica a glicemia em jejum da pessoa, em que: 0 = não é menor que 120 mg/dl e 1 = menor que 120 mg/dl.	Inteiro
7	restecg	Indica os resultados do eletrocardiograma em repouso, em que: 0 = provável ou definitiva hipertrofia ventricular esquerda pelos critérios de Estes, 1 = normal e 2 = anormalidade na onda ST-T.	Inteiro
8	thalach	Indica a frequência cardíaca máxima alcançada pela pessoa.	Inteiro
9	exang	Indica se houve angina induzida por exercício, em que: 0 = não e 1 = sim.	Inteiro
10	oldpeak	Indica a depressão do segmento ST induzida por exercício em relação ao repouso.	Float
11	slope	Indica a inclinação do segmento ST no pico do exercício, em que: 0 = descendente, 1 = plano e 2 = ascendente.	Inteiro
12	ca	Indica o número de vasos principais, variando de 0 a 3.	Inteiro
13	thal	Indica o resultado do teste de talassemia, em que: 1 = normal, 2 = defeito fixo e 3 = defeito reversível.	Inteiro
14	target	Indica a presença de doença cardíaca no paciente, em que: 0 = não possui doença cardíaca e 1 = possui doença cardíaca.	Inteiro

das acurácias de cada método. A média foi utilizada como principal medida de desempenho, enquanto o desvio padrão permitiu analisar a estabilidade dos modelos ao longo das diferentes execuções.

3.1. Tecnologias:

Para realizar a implementação, treinamento e testagem das CNNs, foi utilizado o computador pessoal de um dos autores cujo os componentes são:

- Processador: Ryzen 5 7600X (6 núcleos e 12 threads com clock de até 4,7GHz)
- Memória: 32 GB (2 módulos de 16 GB DDR5 rodando a 5200 MT/s)

Em relação aos softwares utilizados, estão apresentados a seguir:

- Sistema Operacional: Windows 11 pro 25H2
- Ambiente de Desenvolvimento: Visual Studio Code e Jupyter Notebook

- Linguagem: Python 3.12.9

As bibliotecas utilizadas foram:

- pandas
- sklearn
- matplotlib
- numpy
- seaborn
- warnings

4. Modelos Avaliados

Nessa seção serão apresentados todos os classificadores utilizados, eles estão divididos entre Monolíticos e de Combinação/*Ensemble*.

4.1. Classificadores Monolíticos

4.1.1. *K-Nearest Neighbors* (KNN)

O algoritmo *K-Nearest Neighbors* (KNN) realiza a classificação de uma nova instância com base nas classes das amostras mais próximas presentes no conjunto de treinamento, considerando uma medida de distância entre os exemplares [Brun 2026a].

Para a calibração do modelo, foram avaliados diferentes valores para o número de vizinhos, representado pelo parâmetro k , variando de 1 até 50. Além disso, foram testadas diferentes estratégias de ponderação dos vizinhos: sem ponderação, ponderação pelo inverso da distância euclidiana e ponderação por 1 menos a distância normalizada.

A estratégia sem ponderação considera que todos os vizinhos possuem o mesmo peso no processo de decisão. Já nas estratégias ponderadas, os vizinhos mais próximos exercem maior influência na definição da classe final, enquanto vizinhos mais distantes possuem menor peso.

4.1.2. Árvore de Decisão

A Árvore de Decisão realiza a classificação das instâncias por meio de uma estrutura hierárquica composta por nós de decisão e folhas. Em cada nó, um atributo é selecionado para dividir os dados, buscando separar as classes da melhor forma possível até que seja atingido algum critério de parada ou uma folha da árvore [Brun 2026f].

Para a calibração do modelo, foram avaliadas diferentes configurações de hiperparâmetros relacionados à construção da árvore, conforme a Tabela 2. Foram variados o critério de seleção dos atributos, o divisor dos atributos, a profundidade máxima da árvore, o número mínimo de amostras necessário para realizar a divisão de um nó e o número mínimo de elementos permitidos em cada folha.

O critério de seleção dos atributos define a medida utilizada para escolher quais atributos serão empregados nas divisões da árvore. Já o parâmetro *splitter* determina a estratégia usada para escolher a melhor divisão em cada nó. A profundidade máxima controla o crescimento da árvore, evitando que o modelo se torne excessivamente complexo. Além disso, os parâmetros referentes ao número mínimo de amostras para divisão

de um nó e ao número mínimo de elementos por folha foram utilizados para controlar o nível de generalização do modelo.

Tabela 2. Hiperparâmetros avaliados para a Árvore de Decisão

Hiperparâmetro	Valores avaliados
Critério de seleção dos atributos	<i>entropy</i> e <i>gini</i>
Splitter	<i>best</i> e <i>random</i>
Profundidade máxima	Valores inteiros de 1 até 10
Mínimo para divisão do nó	Valores inteiros de 2 até 15
Mínimo de elementos por folha	Valores inteiros de 1 até 10

4.1.3. Naive Bayes

O classificador Naive Bayes é baseado no Teorema de Bayes e assume independência condicional entre os atributos, ou seja, considera que cada atributo contribui de forma independente para a definição da classe final [Brun 2026c].

Diferentemente dos demais modelos avaliados, o Naive Bayes não teve hiperparâmetros variados durante a etapa de calibração, tendo sido usado seu modelo *default*.

4.1.4. Support Vector Machine (SVM)

O classificador *Support Vector Machine* (SVM) busca encontrar uma fronteira de decisão capaz de separar as classes da melhor forma possível, maximizando a margem entre os exemplos de diferentes classes [Brun 2026e].

Para a calibração do modelo, foram avaliadas diferentes combinações dos hiperparâmetros Valor de erro (C) e *kernel*. Valores menores de (C) permitem uma margem mais flexível, aceitando mais erros, enquanto valores maiores tornam o modelo mais rígido, buscando reduzir ao máximo os erros no conjunto de treinamento.

Neste experimento, os valores testados para (C) foram 0.1, 1, 10 e 100. Também foram avaliados três tipos de *kernel*: *linear*, *rbf* e *sigmoid*. O *kernel linear* busca separar as classes por meio de uma fronteira linear, enquanto o *rbf* permite a construção de fronteiras de decisão não lineares. Já o *sigmoid* aplica uma transformação baseada na função sigmoide, oferecendo outra alternativa para a separação das classes.

Além disso, o classificador foi configurado com o parâmetro *probability=True*, permitindo a obtenção das probabilidades associadas às classes. Essa informação foi utilizada posteriormente nas estratégias de combinação de classificadores que dependem dos percentuais de confiança dos modelos .

4.1.5. Multilayer Perceptron (MLP)

O classificador *Multilayer Perceptron* (MLP) é baseado em redes neurais artificiais do tipo *feedforward*, compostas por camadas de neurônios interconectados. O MLP busca

aprender padrões presentes nos dados por meio do ajuste dos pesos das conexões entre os neurônios durante o processo de treinamento [Brun 2026b].

Para a calibração do modelo, foram avaliadas diferentes combinações de hiperparâmetros relacionados à arquitetura da rede e ao processo de treinamento. Foram variados o número de épocas de treinamento, a taxa de aprendizagem, o número de camadas escondidas, a quantidade de neurônios na camada escondida, a função de ativação e o tamanho do *batch*, como é mostrado na tabela Tabela 3.

A taxa de aprendizagem controla a intensidade das atualizações dos pesos. Taxas muito baixas tornam o processo de treinamento mais lento, enquanto taxas muito altas podem fazer com que o modelo oscile e tenha dificuldade para alcançar uma boa solução. Também foram avaliados o número de camadas escondidas e a quantidade de neurônios em cada camada, pois esses parâmetros afetam diretamente a capacidade da rede de representar padrões mais complexos.

As funções de ativação avaliadas foram *tanh*, *relu* e *logistic*. Essas funções introduzem não linearidade ao modelo, permitindo que a rede aprenda fronteiras de decisão mais flexíveis. Por fim, o tamanho do *batch* determina quantas amostras são utilizadas em cada atualização dos pesos, influenciando tanto a estabilidade quanto o tempo de treinamento.

Tabela 3. Hiperparâmetros avaliados para o MLP

Hiperparâmetro	Valores avaliados
Número de épocas de treino	100, 500 e 1000.
Taxa de aprendizagem	0.0001, 0.001, 0.01 e 0.1.
Número de camadas densas	1 e 2
Quantidade de neurônios na camada escondida	13, 15, 17, 19, 21, 23 e 25 neurônios.
Função de ativação	<i>tanh</i> , <i>relu</i> e <i>logistic</i> .
Tamanho do <i>batch</i>	16, 32 e 64.

4.2. Métodos *Ensemble*

Nesta seção serão apresentadas os modelos cuja estratégia de classificação é baseada em Sistemas de Múltiplos Classificadores.

4.2.1. *Bagging*

O método *Bagging* consiste em treinar vários classificadores sobre diferentes subconjuntos amostrados a partir do conjunto de treinamento, combinando posteriormente suas decisões para produzir uma classificação final. O objetivo do *Bagging* é reduzir a variância do modelo e aumentar sua capacidade de generalização [Brun 2026d].

Para a calibração do *Bagging*, foram avaliadas diferentes configurações relacionadas ao número de estimadores, ao tamanho das amostras utilizadas em cada subconjunto e ao classificador base empregado, os valores variados se encontram na Tabela 4. Os classificadores utilizados como estimadores base foram KNN, SVM, Naive Bayes, MLP e Árvore de Decisão, todos configurados com seus hiperparâmetros padrão.

O número de estimadores define a quantidade de classificadores gerados pelo *Bagging*. Quanto maior esse número, mais estável tende a ser a decisão final, pois a classificação passa a considerar a combinação de vários modelos. No entanto, isso também aumenta o custo computacional do treinamento e da predição.

O número de amostras para cada subconjunto controla a proporção do conjunto de treinamento utilizada por cada estimador. Subconjuntos menores tendem a gerar classificadores mais diversos, enquanto subconjuntos maiores fornecem mais informação para cada modelo, mas podem tornar os classificadores mais semelhantes entre si.

Os estimadores base foram utilizados com seus hiperparâmetros padrão. Assim, a calibração do *Bagging* concentrou-se na quantidade de classificadores, no tamanho dos subconjuntos de treinamento e no tipo de modelo utilizado como base.

Tabela 4. Hiperparâmetros avaliados para o Bagging

Hiperparâmetro	Valores avaliados
Número de estimadores	10, 50 e 100.
Número de amostras para cada subconjunto	0.2, 0.4, 0.6 e 0.8 do conjunto de treinamento.
Estimador base	KNN, SVM, Naive Bayes, MLP e Árvore de Decisão, todos com hiperparâmetros padrão.

4.2.2. Random Forest

O modelo *Random Forest* é composto por um conjunto de árvores de decisão, em que cada árvore é treinada a partir de diferentes amostras do conjunto de treinamento e considerando subconjuntos de atributos durante as divisões. A classificação final é obtida pela combinação das decisões das árvores, geralmente por votação [Scikit-learn Developers 2026].

Para a calibração do *Random Forest*, foram avaliadas diferentes combinações de hiperparâmetros relacionados à quantidade de árvores e à estrutura de cada árvore do conjunto. Foram variados o número de estimadores, o critério de seleção dos atributos, a profundidade máxima, o número mínimo de amostras necessário para realizar a divisão de um nó e o número mínimo de elementos permitidos em cada folha.

Os hiperparâmetros avaliados para o *Random Forest* são apresentados na Tabela 5. O número de estimadores define quantas árvores compõem a floresta, influenciando a estabilidade da decisão final, já que o resultado passa a depender da combinação de múltiplas árvores.

O critério de seleção dos atributos determina como cada árvore escolhe as melhores divisões dos dados. Já a profundidade máxima controla o crescimento das árvores, evitando que elas se tornem excessivamente específicas para o conjunto de treinamento.

Além disso, o número mínimo de amostras para divisão de um nó e o número mínimo de elementos por folha foram utilizados para controlar a complexidade das árvores. Esses parâmetros ajudam a evitar divisões baseadas em poucos exemplos, contribuindo para uma melhor generalização do modelo.

Tabela 5. Hiperparâmetros avaliados para o Random Forest

Hiperparâmetro	Valores avaliados
Número de estimadores	50, 100 e 150.
Critério de seleção dos atributos	<i>gini</i> e <i>entropy</i> .
Profundidade máxima	<i>None</i> , 10 e 20.
Mínimo para divisão do nó	2 e 5.
Mínimo de elementos por folha	1 e 2.

4.2.3. Boosting

O método *Boosting* consiste em treinar classificadores de forma sequencial, dando maior atenção às instâncias classificadas incorretamente nas etapas anteriores. Dessa forma, o modelo busca corrigir progressivamente os erros cometidos pelos classificadores anteriores, produzindo uma decisão final mais robusta [Brun 2026d].

Para a calibração do modelo, foram avaliadas diferentes combinações relacionadas ao número de estimadores, ao classificador base utilizado e à taxa de aprendizado. Os classificadores empregados como estimadores base foram SVM, Naive Bayes e Árvore de Decisão, todos configurados com seus hiperparâmetros padrão.

Os hiperparâmetros avaliados para o *Boosting* são apresentados na Tabela 6. O número de estimadores define quantos classificadores serão treinados em sequência, influenciando a capacidade do método de corrigir erros ao longo das iterações.

O estimador base indica qual modelo será utilizado em cada etapa do processo. Como cada classificador possui um comportamento diferente, essa escolha pode alterar a forma como o *Boosting* aprende e ajusta suas decisões.

A taxa de aprendizado controla a contribuição de cada estimador para o modelo final. Valores menores tornam as atualizações mais suaves, enquanto valores maiores fazem com que cada classificador tenha maior influência na decisão final.

Tabela 6. Hiperparâmetros avaliados para o Boosting

Hiperparâmetro	Valores avaliados
Número de estimadores	50, 100 e 200.
Estimador base	SVM, Naive Bayes e Árvore de Decisão, todos com hiperparâmetros padrão.
Taxa de aprendizado	0.0001, 0.001, 0.01 e 0.1.

4.3. Estratégias de Combinação

Após a calibração dos classificadores monolíticos, foram avaliadas três estratégias de combinação de modelos: Regra da Soma, Voto Majoritário e Borda Count. Essas abordagens utilizaram os cinco classificadores individuais previamente treinados e calibrados: KNN, Árvore de Decisão, MLP, SVM e Naive Bayes. Dessa forma, não foi realizado um novo processo de treinamento, mas sim a combinação das predições ou probabilidades geradas por esses modelos.

4.3.1. Regra da Soma

Na Regra da Soma cada modelo fornece as probabilidades associadas a cada classe. Em seguida, para cada amostra as probabilidades atribuídas pelos diferentes classificadores são somadas classe a classe [Brun 2026d].

Após a soma das probabilidades, a classe escolhida para cada instância é aquela que apresenta o maior valor acumulado. Dessa forma, a decisão final considera não apenas a classe prevista por cada modelo, mas também o grau de confiança associado a cada predição.

Essa estratégia combinou as saídas dos classificadores KNN, Árvore de Decisão, MLP, SVM e Naive Bayes. A acurácia da combinação foi então calculada a partir da comparação entre as classes previstas pela regra e as classes reais do conjunto avaliado.

4.3.2. Voto Majoritário ou Produto

O Voto Majoritário não utiliza diretamente as probabilidades associadas às classes, mas sim a classe final prevista por cada modelo individual [Brun 2026d].

Para cada amostra, foram coletadas as predições dos cinco classificadores monolíticos: KNN, Árvore de Decisão, MLP, SVM e Naive Bayes. Em seguida, foi realizada uma contagem dos votos recebidos por cada classe. A classe com o maior número de votos foi escolhida como a predição final da combinação.

Essa abordagem permite avaliar se a decisão conjunta dos classificadores é capaz de produzir um desempenho superior ao dos modelos individuais. A acurácia do Voto Majoritário foi calculada comparando as classes finais escolhidas pela votação com as classes reais do conjunto avaliado.

4.3.3. Borda Count

O método Borda Count é baseado no ranqueamento das classes produzido por cada classificador. Nessa abordagem, cada modelo fornece as probabilidades associadas a cada classe, e essas probabilidades são utilizadas para ordenar as classes da menos provável para a mais provável [Brun 2026d].

Para cada classificador e para cada amostra, a classe com menor probabilidade recebe a menor pontuação, enquanto a classe com maior probabilidade recebe a maior pontuação. Após isso, as pontuações atribuídas pelos cinco classificadores são somadas para cada classe.

A classe escolhida como predição final é aquela que apresenta a maior pontuação acumulada ao final do processo. Dessa forma, o Borda Count considera não apenas a classe mais provável para cada modelo, mas também a posição relativa de cada classe no ranqueamento de probabilidades. Neste trabalho, essa estratégia combinou as saídas dos classificadores KNN, Árvore de Decisão, MLP, SVM e Naive Bayes, sendo a acurácia calculada a partir das predições finais obtidas.

5. Resultados dos Classificadores Monolíticos

Na Tabela 7 estão apresentados os resultados dos modelos treinados na base de dados. Todos os modelos foram avaliados utilizando a mesma divisão de 50% para treino e 25% para teste e validação, sorteada no início do processo para garantir que nenhum classificador fosse favorecido ou prejudicado por uma partição específica de dados. Este procedimento foi repetido 20 vezes para conferir robustez ao estudo e garantir resultados estatisticamente válidos.

Tabela 7. Resultados das execuções para os classificadores monolíticos

Execução	AD (%)	KNN (%)	MLP (%)	NB (%)	SVM (%)
1	94,94	94,55	89,11	79,77	85,60
2	96,50	92,22	85,60	81,32	82,88
3	91,05	94,55	85,21	81,71	85,21
4	95,72	91,44	86,77	82,10	86,38
5	96,11	96,50	89,88	82,88	84,44
6	95,33	96,50	89,88	85,60	87,16
7	96,89	97,28	85,21	82,88	85,99
8	95,33	91,83	85,21	82,88	83,27
9	97,28	95,33	84,44	80,16	81,71
10	96,89	94,94	85,99	82,10	84,05
11	94,94	92,61	89,11	84,05	84,05
12	95,72	97,28	92,61	85,60	87,55
13	95,33	88,72	85,21	78,99	78,99
14	93,39	93,00	86,38	83,66	87,55
15	98,05	94,16	85,99	85,60	85,60
16	94,94	89,88	84,44	85,99	87,16
17	94,94	94,16	80,16	78,21	80,16
18	95,72	95,72	92,61	84,44	86,38
19	95,33	92,22	85,60	79,38	80,16
20	95,33	91,83	83,27	79,77	86,38
Média	95,49	93,74	86,63	82,35	84,53
Desvio Padrão	1,46	2,39	3,07	2,43	2,60

Os valores apresentados exibem as acurácias dos modelos nos conjuntos de teste e, ao final da tabela, encontram-se as médias das acurácias acompanhadas de seus respectivos desvios padrões. Para este trabalho, o uso da acurácia como métrica principal é adequado, visto que a base de dados é praticamente equilibrada, conforme apresentado na Seção 2.

Para verificar se as diferenças observadas entre os classificadores foram estatisticamente significativas, foram aplicados testes estatísticos não paramétricos com nível de confiança de 95%. Inicialmente, foi utilizado o teste de Kruskal-Wallis para avaliar se havia diferença global entre os desempenhos dos métodos. Em seguida, quando identificada diferença significativa, foi aplicado o teste de Mann-Whitney para realizar as comparações par a par entre os classificadores.

Para os classificadores monolíticos, o teste de Kruskal-Wallis apresentou estatís-

tica de 76,6893 e p-valor igual a $8,7501 \times 10^{-16}$. Como o p-valor foi inferior a 0,05, rejeita-se a hipótese nula de igualdade entre os métodos. Portanto, há evidência estatística de que pelo menos um dos classificadores monolíticos apresentou desempenho significativamente diferente dos demais.

Na comparação par a par entre os classificadores monolíticos, conforme apresentado na Tabela 8, observou-se que a maioria dos modelos apresentou diferença significativa entre si. A comparação entre AD e KNN apresentou p-valor de 0,0122, indicando diferença estatisticamente significativa. A AD também apresentou diferença significativa em relação ao MLP, NB e SVM. O KNN, por sua vez, foi significativamente diferente de MLP, NB e SVM. Também houve diferença significativa entre MLP e NB, além de NB e SVM. A única comparação que não apresentou diferença estatisticamente significativa foi entre MLP e SVM, com p-valor de 0,1081, indicando desempenho estatisticamente semelhante entre esses dois modelos.

Tabela 8. Resultados do Teste de Mann-Whitney (Dois a Dois) para os Modelos Monolítico

Modelo 1	Modelo 2	p-valor	Significância (Conclusão)
AD	KNN	0,0122	Significativo (Diferentes)
AD	MLP	0,0000	Significativo (Diferentes)
AD	NB	0,0000	Significativo (Diferentes)
AD	SVM	0,0000	Significativo (Diferentes)
KNN	MLP	0,0000	Significativo (Diferentes)
KNN	NB	0,0000	Significativo (Diferentes)
KNN	SVM	0,0000	Significativo (Diferentes)
MLP	NB	0,0000	Significativo (Diferentes)
MLP	SVM	0,1081	Não Significativo (Iguais)
NB	SVM	0,0061	Significativo (Diferentes)

Dessa forma, entre os classificadores monolíticos, os testes indicaram diferenças relevantes entre praticamente todos os modelos avaliados, com exceção da comparação entre MLP e SVM. Considerando a média de acurácia, o melhor classificador monolítico foi a Árvore de Decisão, com média de 95,49%.

6. Resultados dos Métodos *Ensemble* e Combinação

Na Tabela 9 estão apresentados os resultados dos modelos treinados na base de dados. Todos os testes foram realizados utilizando as mesmas configurações do exemplo anterior.

Para os métodos ensemble e estratégias de combinação, o teste de Kruskal-Wallis também indicou diferença significativa entre os métodos, com estatística de 75,5007 e p-valor igual a $7,3133 \times 10^{-15}$. Como o p-valor foi inferior a 0,05, rejeita-se novamente a hipótese nula, indicando que pelo menos uma das abordagens apresentou desempenho estatisticamente diferente das demais.

Nas comparações par a par entre os métodos ensemble e de combinação, apresentada na Tabela 10, Bagging e Boosting não apresentaram diferença estatisticamente significativa, com p-valor de 0,7584. Bagging e Random Forest também não apresentaram diferença significativa, com p-valor de 0,1274. Entretanto, Bagging apresentou diferença significativa em relação às estratégias Soma, Produto e Borda Count.

Tabela 9. Resultados das execuções para os classificadores *ensemble* e combinação

Execução	Baggin (%)	Boosting (%)	Soma (%)	Voto majoritário (%)	Borda Count (%)	RF (%)
1	97,28	94,16	94,55	92,22	92,22	96,89
2	94,94	96,50	88,72	88,33	88,33	95,72
3	97,28	96,50	90,27	87,16	87,16	95,72
4	95,33	95,33	94,55	91,83	92,22	94,55
5	98,05	97,67	94,94	92,61	92,61	98,44
6	96,11	94,94	94,16	92,22	92,22	96,89
7	96,50	97,67	96,11	91,44	91,44	97,28
8	92,61	96,50	91,83	89,49	89,49	95,33
9	96,89	96,89	93,00	89,49	89,49	97,28
10	96,89	92,22	93,77	88,72	88,72	97,28
11	97,28	93,77	93,39	91,05	91,05	96,89
12	96,11	94,94	95,33	93,77	93,77	97,28
13	92,61	97,28	92,22	87,55	88,33	93,39
14	94,94	94,16	91,83	90,27	90,27	94,94
15	92,22	93,39	91,44	90,66	90,66	95,72
16	93,00	96,89	95,72	91,05	91,05	96,89
17	94,94	94,55	93,00	87,16	88,33	95,33
18	95,72	93,77	96,11	94,16	94,16	97,67
19	93,39	93,77	90,27	87,16	87,16	96,11
20	95,33	93,39	93,77	91,44	91,44	95,72
Média	95,37	95,21	93,25	90,39	90,51	96,27
Desvio Padrão	1,78	1,65	2,07	2,18	2,07	1,22

O Boosting apresentou diferença significativa em relação à Soma, Produto, Borda Count e Random Forest. A comparação entre Boosting e Random Forest apresentou p-valor de 0,0402, indicando diferença estatisticamente significativa entre esses métodos. A estratégia Soma também apresentou diferença significativa em relação a Produto, Borda Count e Random Forest. Por outro lado, Produto e Borda Count não apresentaram diferença estatisticamente significativa entre si, com p-valor de 0,9042.

Assim, pode-se observar que dentre os Sistemas de Múltiplos Classificadores e de Combinação o Random Forest foi, em relação à acurácia, o que apresentou melhor desempenho, sendo ela de 96,27%. Com tudo, o teste de Mann-Whitney indicou que este método não possui diferença significativa quando comparado ao Bagging, que apresentou acurácia de 95,37%.

7. Comparação Final: Melhor Monolítico x Melhor *Ensemble*/Combinação

Por fim, foi realizada a comparação entre o melhor classificador monolítico e o melhor método ensemble. A Árvore de Decisão foi o melhor modelo monolítico, com acurácia média de 95,49%, enquanto o Random Forest foi o melhor método ensemble, com média de 96,27%. A comparação entre ambos por meio do teste de Mann-Whitney resultou em p-valor de 0,0402. Como esse valor é inferior a 0,05, conclui-se que há diferença estatisticamente significativa entre os dois métodos.

Assim, o Random Forest apresentou o melhor desempenho geral do experimento. Embora a diferença média em relação à Árvore de Decisão tenha sido pequena, ela foi estatisticamente significativa. Portanto, para a base de dados avaliada, a abordagem baseada

Tabela 10. Resultados do Teste de Mann-Whitney (Dois a Dois) para Ensembles e Combinações

Modelo 1	Modelo 2	p -valor	Significância (Conclusão)
BAGGING	BOOSTING	0,7584	Não Significativo (Iguais)
BAGGING	Soma	0,0014	Significativo (Diferentes)
BAGGING	Produto	0,0000	Significativo (Diferentes)
BAGGING	Borda Count	0,0000	Significativo (Diferentes)
BAGGING	RF	0,1274	Não Significativo (Iguais)
BOOSTING	Soma	0,0061	Significativo (Diferentes)
BOOSTING	Produto	0,0000	Significativo (Diferentes)
BOOSTING	Borda Count	0,0000	Significativo (Diferentes)
BOOSTING	RF	0,0402	Significativo (Diferentes)
Soma	Produto	0,0002	Significativo (Diferentes)
Soma	Borda Count	0,0003	Significativo (Diferentes)
Soma	RF	0,0000	Significativo (Diferentes)
Produto	Borda Count	0,9042	Não Significativo (Iguais)
Produto	RF	0,0000	Significativo (Diferentes)
Borda Count	RF	0,0000	Significativo (Diferentes)

em ensemble apresentou desempenho superior ao melhor classificador monolítico.

8. Conclusão

Este trabalho apresentou uma comparação experimental entre diferentes métodos de classificação aplicados ao *Heart Disease Dataset*. Foram avaliados classificadores monolíticos, métodos ensemble e estratégias de combinação, considerando a acurácia como métrica principal de desempenho. Para aumentar a confiabilidade da análise, os experimentos foram repetidos 20 vezes, com divisão dos dados em conjuntos de treinamento, validação e teste.

Entre os classificadores monolíticos, a Árvore de Decisão apresentou o melhor desempenho médio, com acurácia de 95,49%. Esse resultado indica que o modelo foi capaz de representar de forma eficiente as relações entre os atributos da base e a classe-alvo. A análise estatística também indicou diferença significativa entre a maioria dos classificadores individuais, sendo que apenas a comparação entre MLP e SVM não apresentou diferença estatisticamente significativa.

Entre os métodos ensemble e as estratégias de combinação, o Random Forest obteve o melhor desempenho geral, com acurácia média de 96,27%. Apesar de o Bagging também ter apresentado bom desempenho, a maior média foi obtida pelo Random Forest, evidenciando a vantagem da combinação de múltiplas árvores de decisão para a base utilizada. Além disso, a comparação estatística entre Random Forest e Árvore de Decisão apresentou diferença significativa, indicando que o melhor método ensemble superou o melhor classificador monolítico.

De modo geral, os resultados mostram que os métodos baseados em múltiplos classificadores foram superiores em relação aos modelos individuais, com destaque para o Random Forest. Embora a diferença média em relação à Árvore de Decisão tenha sido

pequena, ela foi estatisticamente significativa. Assim, conclui-se que, para o problema analisado, a utilização de uma abordagem ensemble apresentou melhor desempenho do que o uso isolado do melhor classificador monolítico.

Referências

- Brun, A. L. (2026a). K-nearest neighbors - knn. Slides da disciplina Aprendizagem de Máquina. Universidade Estadual do Oeste do Paraná.
- Brun, A. L. (2026b). Multilayer perceptron. Slides da disciplina Aprendizagem de Máquina. Universidade Estadual do Oeste do Paraná.
- Brun, A. L. (2026c). Naive bayes. Slides da disciplina Aprendizagem de Máquina. Universidade Estadual do Oeste do Paraná.
- Brun, A. L. (2026d). Sistemas de múltiplos classificadores. Slides da disciplina Aprendizagem de Máquina. Universidade Estadual do Oeste do Paraná.
- Brun, A. L. (2026e). Support vector machine. Slides da disciplina Aprendizagem de Máquina. Universidade Estadual do Oeste do Paraná.
- Brun, A. L. (2026f). Árvores de decisão. Slides da disciplina Aprendizagem de Máquina. Universidade Estadual do Oeste do Paraná.
- Lapp, D. (2019). Heart disease dataset. Disponível em: <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>. Acesso em: 17 maio 2026.
- Scikit-learn Developers (2026). Randomforestclassifier. Documentação do scikit-learn. Acesso em: 21 maio 2026.